

基于强化学习算子调度与多种群救援机制的自适应遗传算法

姓名：张跃晨 学号:1131230113 班级: 信计 2301 班

摘要：针对高维复杂连续优化问题中遗传算法在算子选择与多种群协同方面适应性不足、易早熟收敛的问题，本文提出了一种融合尺度不变强化学习控制与停滞感知救援机制的多种群自适应遗传算法（MPRL-GA）。在微观层面，将遗传算子调度建模为马尔可夫决策过程，引入基于历史分位数的滑动窗口状态建模方法，构建尺度不变的演化状态空间，使强化学习智能体能够在不同适应度景观下稳定感知搜索态势并动态选择算子组合。在宏观层面，针对传统岛屿模型中固定迁移策略易导致无效迁移与负迁移的问题，提出了一种基于演化停滞检测的“源-汇”救援迁移机制，仅在子种群陷入停滞时触发定向精英注入，并通过噪声扰动维持多样性。在 9 个标准连续优化基准函数（ $D = 30$ ）上的实验结果表明，与传统 GA、PSO、DE 等经典算法及消融变体相比，所提出方法在多峰及病态函数上表现出更稳定的收敛行为和更强的全局寻优能力，尤其在 Rosenbrock 与 Schwefel 函数上显著降低了对初始条件的敏感性。实验分析进一步验证了尺度不变状态建模与停滞感知迁移机制之间的协同效应。

关键词：遗传算法；多种群协同进化；强化学习；自适应策略；智能优化

1 引言

遗传算法（Genetic Algorithm, GA）作为一种模拟自然选择机制的随机全局优化方法，因其不依赖梯度信息且具备强大的并行搜索能力，被广泛应用于工程设计、参数反演及组合优化等复杂领域^[1-2]。然而，作为一种典型的启发式算法，传统 GA 的性能高度依赖于算子形式与参数设置。在面对多峰、高维或具有欺骗性的适应度景观时，采用固定交叉变异概率的静态策略往往难以在全局探索与局部开发之间维持动态平衡，极易导致种群多样性丧失，从而陷入早熟收敛或搜索停滞^[3]。

针对上述问题，研究者提出了多种改进思路，主要包括参数自适应控制、多种群协同进化以及基于机器学习的智能辅助策略。参数自适应方法通过进化反馈动态调整控制参数，在一定程度上缓解了固定参数带来的性能退化问题，但其调节规则多依赖预设启发式假设，难以在复杂适应度景观中保持稳定有效^[4-5]。多种群遗传算法（如岛屿模型）通过并行子种群搜索延缓种群同质化，有助于提升全局多样性^[6-7]，但现有方法多采用固定迁移拓扑与频率，忽略了子种群演化状态差异，可能引发无效迁移甚至负迁移现象。

近年来，强化学习（Reinforcement Learning, RL）被引入进化计算领域，用于实现遗传算子的在线自适应调度^[8-9]。通过将算子选择建模为序列决策问题，RL 智能体能够依据环境反馈不断优化控制策略。然而，现有 RL-GA 方法仍存在两个关键不足：一方面，状态空

间通常直接由适应度值或其统计量构成，具有明显的尺度敏感性，导致算法在不同量级或不同景观的优化问题上泛化能力受限；另一方面，算子调度策略往往仅关注短期适应度增益，忽视多样性维持与长期搜索潜力之间的权衡，从而在复杂多峰问题中仍可能陷入局部最优^[10-11]。

基于上述分析，本文认为：**提升强化学习辅助遗传算法泛化能力的关键，在于构建与问题尺度无关的演化状态建模方式，并将算子调度与多种群协同机制在统一的演化反馈框架下加以协调。**为此，本文提出了一种融合尺度不变强化学习控制与停滞感知迁移机制的多种群自适应遗传算法（MPRL-GA）。在微观层面，通过引入基于历史分位数的滑动窗口方法，对种群多样性与适应度改进率进行相对化建模，从而构建尺度不变的强化学习状态空间，实现算子组合的自适应调度；在宏观层面，针对传统多种群模型中迁移策略缺乏状态感知的问题，设计了一种基于演化停滞检测的“源-汇”救援迁移机制，仅在子种群搜索受阻时触发定向干预，以避免负迁移并维持全局多样性。

1. 提出了一种基于分位数统计的尺度不变强化学习状态建模方法，有效缓解了传统 RL-GA 在不同适应度景观下状态定义依赖绝对量级的问题，提升了算子调度策略的稳定性与泛化能力。
2. 设计了一种演化停滞感知的多种群救援迁移机制，通过“源-汇”动态识别与噪声扰动注入，实现对陷入早熟收敛子种群的定向干预，避免无效迁移带来的性能退化。

3. 构建并验证了一个融合强化学习控制与多种群协同的自适应遗传算法框架，在多个标准连续优化基准函数上系统评估了各机制的独立作用及其协同效果

2 相关工作

本节简要回顾与本文研究密切相关的三个领域：参数自适应遗传算法、多种群岛屿模型以及基于强化学习的进化计算。

2.1 遗传算法与参数自适应控制

遗传算法 (Genetic Algorithm, GA) 的搜索性能高度依赖交叉、变异等控制参数及算子配置^[1-2,12]。标准 GA 采用静态参数设置，在多峰、高维或具有欺骗性的适应度景观中，往往难以兼顾全局探索与局部开发，容易导致多样性过快衰减和早熟收敛。结合“没有免费午餐”定理 (NFL)^[3]，不存在对所有问题均有效的通用参数配置，因此有必要引入动态参数与算子控制机制。

围绕上述问题，研究者提出了确定性、自适应与自组织等多类参数控制方法^[5]。其中，自适应方法（如 1/5 成功法则^[4] 及自适应交叉/变异概率策略^[13]）利用搜索反馈动态调整参数，在一定程度上提升了算法鲁棒性，但其调节规则多依赖局部统计信息，在复杂地貌中仍可能表现出短视性。因此，如何构建具备全局视角的算子调度策略仍是遗传算法研究的重要问题。

2.2 多种群遗传算法（岛屿模型）

多种群遗传算法（典型代表为岛屿模型）通过并行子种群搜索和迁移操作延缓种群同质化，从而提升全局搜索能力^[6-7]。现有研究主要集中在迁移拓扑结构和迁移参数的设计上^[6-7,14]。

然而，传统岛屿模型多采用固定迁移周期与固定迁移策略，忽略子种群实时演化状态差异。当子种群趋于同质化时，迁移可能成为无效交换；而不恰当的迁移还可能导致劣质信息传播，引发负迁移现象^[7]。因此，构建能够感知子种群停滞状态并按需触发的动态迁移机制，是提升多种群协同效率的关键方向。

2.3 进化计算中的强化学习辅助策略

近年来，强化学习 (Reinforcement Learning, RL) 被广泛用于进化算法的在线参数控制与算子选择^[8,15-16]。在该框架下，进化算法被视为环境，RL 智

能体通过感知演化状态并执行控制动作以优化长期回报。

已有研究利用 Q-learning 实现了算子自适应调度^[9-11]，但仍存在两个突出问题：其一，状态特征多直接依赖适应度值或其统计量，对问题尺度高度敏感，限制了策略的泛化能力；其二，奖励设计往往偏向短期适应度增益，忽视多样性维持，容易加剧早熟收敛^[10]。针对上述不足，本文提出基于分位数统计的尺度不变状态建模方法，并结合停滞感知的救援迁移机制，在微观算子调度与宏观多种群协同之间建立统一框架。

表 1 从状态建模、算子调度和迁移策略等关键设计维度，对本文方法与典型相关研究进行了对比。可以看出，本文方法通过尺度不变的强化学习状态建模与按需触发的救援迁移机制，显式缓解了状态尺度敏感性与负迁移风险，为复杂连续优化问题提供了一种更稳健的协同进化思路。

表 1: 不同方法在关键设计维度上的对比

方法	状态定义 尺度不变	算子自适 应调度	迁移按需 触发	抑制负 迁移
传统 GA (静态参数)	×	×	—	—
参数自适应 GA	×	✓	—	—
RL-GA (固定阈值)	×	✓	—	—
固定迁移多种群 GA	×	×	×	×
MPRL-GA (本文)	✓	✓	✓	✓

注：✓ 表示支持，× 表示不支持，— 表示不适用

3 算法设计

3.1 整体框架

3.1.1 问题定义

不失一般性，本文考虑如下的单目标连续全局优化问题：

$$\min f(\mathbf{x}), \quad \text{s.t.} \quad \mathbf{x} \in \Omega \subseteq \mathbb{R}^D$$

其中， $f: \Omega \rightarrow \mathbb{R}$ 为目标函数， $\mathbf{x} = (x_1, x_2, \dots, x_D)$ 为 D 维决策变量向量，搜索空间 $\Omega = \prod_{i=1}^D [L_i, U_i]$ 由变量上下界约束构成。算法目标是在有限计算预算下逼近全局最优解 $\mathbf{x}^*$ ，使得 $f(\mathbf{x}^*) \leq f(\mathbf{x}), \forall \mathbf{x} \in \Omega$ 。

3.1.2 系统架构与运行机制

MPRL-GA 将强化学习 (RL) 的在线决策能力嵌入多种群遗传算法 (GA) 的并行框架中，形成了一种微




图 1: MPRL-GA 算法整体运行流程图

观自适应，宏观强协同的演化系统。如图 1 所示，算法流程遵循感知—决策—学习—协同的闭环逻辑，主要包含以下三个核心模块：

1. 分布式演化与状态感知

系统初始化 M 个异构子种群并行搜索。在每一代，智能体通过滑动窗口机制（详见 3.2.1 节）提取种群的多样性 (d_t) 与改进率 (η_t) 特征，将高维的演化过程抽象为低维的马尔可夫状态 s_t ，从而解决了传统算法对环境感知迟钝的问题。

2. 强化学习算子调度

各子种群配备独立的 Q-Learning 智能体。基于当前状态 s_t ，智能体根据 ϵ -greedy 策略选择最优算子组合动作 a_t （涵盖选择、交叉、变异类型），指导子种群执行遗传操作。随后，系统根据适应度增益计算奖励 r_t 并更新 Q-Table，不断优化算子选择策略（详见 3.2 节）。

3. 全局协同与知识共享

为突破局部最优，算法引入了双重协同机制（详见 3.3 节）：

Algorithm 1 MPRL-GA 算法整体框架

Require: 种群规模 N ，最大迭代次数 G_{max} ，子种群数量 M ，学习率 α ，折扣因子 γ

Ensure: 全局最优解 $\mathbf{x}^*$

- 1: 初始化 M 个子种群 $\mathcal{P} = \{P_1, \dots, P_M\}$ 及对应的 Q-Table $Q_1, \dots, Q_M$
- 2: 初始化用于状态感知的滑动窗口 W
- 3: **for** $t = 1$ to G_{max} **do**
- 4: **for** $i = 1$ to M **do** ▷ 并行演化
- 5: 计算种群统计特征：多样性 d_t^i 与改进率 η_t^i
- 6: 更新滑动窗口 W^i 并基于分位数阈值确定当前状态 s_t^i
- 7: 基于 ϵ -greedy 策略选择算子组合动作 $a_t^i \leftarrow \pi(s_t^i)$
- 8: 根据 a_t^i 执行选择、交叉及变异操作生成子代 P_i'
- 9: 评估子代适应度并计算多目标奖励 r_t^i
- 10: 观测下一时刻状态 s_{t+1}^i
- 11: 更新 Q 值: $Q_i(s, a) \leftarrow Q_i(s, a) + \alpha[r + \gamma \max_{a'} Q_i(s', a') - Q_i(s, a)]$
- 12: 更新子种群 $P_i \leftarrow P_i'$ (应用精英保留策略)
- 13: **end for**
- 14: **if** $t \bmod T_{mig} == 0$ **then**
- 15: 执行救援迁移策略 (调用 Algorithm 2)
- 16: **end if**
- 17: **if** $t \bmod T_{sync} == 0$ **then**
- 18: 执行多智能体策略同步: $Q_i \leftarrow (1 - \tau)Q_i + \tau\bar{Q}$
- 19: **end if**
- 20: **end for**
- 21: **return** $\mathcal{P}$ 中的历史最优解 $\mathbf{x}^*$

• **演化层面：**基于“源-汇”动力学的救援迁移策略，识别停滞的“汇”种群并注入来自“源”种群的高熵精英流。

• **认知层面：**基于参数加权融合的策略同步机制，允许智能体共享 Q 值表中的元知识，实现群体智慧的涌现。

这种分层架构通过解耦 RL 的局部算子自适应能力与多种群的全局探索机制，并在演化过程中实现二者的动态协同，使算法在复杂适应度地貌下具备更稳定的搜索行为与鲁棒性。

表 2: 分层动作空间详细定义与算子设计意图

动作编号	策略类别	选择算子	交叉算子	变异算子	设计意图与机制特性
a_0 a_1	探索型 (Exploration)	轮盘赌选择	均匀交叉	均匀变异	利用高随机性的均匀分布重置基因, 维持种群多样性,
		锦标赛选择	均匀交叉	均匀变异	防止算法在早期陷入局部最优。
a_2 a_3	平衡型 (Balance)	锦标赛选择	两点交叉	高斯变异 (固定 σ)	标准遗传算法配置, 在保留父代优秀基因模式与
		轮盘赌选择	两点交叉	高斯变异 (固定 σ)	引入随机扰动之间取得折衷, 保证搜索稳定性。
a_4 a_5	开发型 (Exploitation)	排序选择	两点交叉	自适应高斯变异	对精英个体施加高选择压力, 利用与多样性负相关的
		排序选择	均匀交叉	自适应高斯变异	自适应步长 ($\sigma \propto d_t$) 进行精细化局部搜索。

3.2 强化学习驱动的自适应算子选择

为了克服传统遗传算法中静态参数策略对复杂适应度景观适应性差的问题, 本文将算子选择问题建模为离散时间的马尔可夫决策过程 (MDP)^[8]。每个子种群配备一个智能体, 通过与演化环境的交互在线学习最优控制策略。该 MDP 由四元组 $\langle \mathcal{S}, \mathcal{A}, \mathcal{R}, \gamma \rangle$ 定义。

3.2.1 状态空间与尺度不变特征提取

状态定义的质量直接决定了 RL 的泛化能力。针对现有研究中固定阈值难以适应不同基准函数数量级差异的缺陷, 本文提出了一种基于历史分位数的自适应状态离散化机制。

在第 t 代, 智能体观测到的原始特征向量为 $\mathbf{o}_t = [d_t, \eta_t, \xi_t]$, 其中 d_t 为归一化种群多样性, η_t 为适应度改进率, ξ_t 为多种群协同指示量 (例如本代是否发生有效迁移/同步的二值信号, 或由源-汇角色识别得到的协同强度)。为实现尺度不变性, 维护长度为 L 的滑动窗口 $W_t = \{\mathbf{o}_{t-L}, \dots, \mathbf{o}_t\}$, 用于统计各特征的历史分布。对任一特征 $x \in \{d, \eta, \xi\}$, 其离散状态 $S_x(t) \in \{0, 1, 2\}$ 由动态阈值判定:

$$S_x(t) = \begin{cases} 0 \text{ (Low)}, & \text{if } o_{t,x} \leq Q_{30\%}(W_{t,x}) \\ 1 \text{ (Medium)}, & \text{if } Q_{30\%}(W_{t,x}) < o_{t,x} \leq Q_{70\%}(W_{t,x}) \\ 2 \text{ (High)}, & \text{if } o_{t,x} > Q_{70\%}(W_{t,x}) \end{cases} \quad (1)$$

其中, $Q_\tau(\cdot)$ 表示对应百分位的分位数函数。该映射将连续特征划分为相对水平, 从而有效消除适应度绝对量级差异带来的影响。

为构建智能体可识别的全局状态空间, 本文采用三进制编码 (Ternary Encoding) 将多维离散状态线性组合:

$$s_t = S_d(t) \cdot 3^2 + S_\eta(t) \cdot 3^1 + S_\xi(t) \cdot 3^0, \quad (2)$$

从而得到包含 $3^3 = 27$ 个离散状态的集合 $\mathcal{S}$ 。该机制确保智能体感知的是演化过程的相对态势, 而非依赖问题的绝对数值尺度。

3.2.2 分层动作空间

为在有限的动作空间内实现探索与开发的精细化平衡, 本文设计了包含 6 种算子组合的分层动作空间 $\mathcal{A}$ 。如表 2 所示, 各动作根据其对种群多样性的影响程度, 被逻辑划分为探索型、平衡型与开发型三类, 分别对应不同的进化阶段需求。

3.2.3 多目标奖励塑形与策略更新

为在加速收敛与维持种群多样性之间建立动态平衡, 本文设计复合奖励函数 r_t , 由收敛增益、多样性变化与历史突破三部分构成, 并引入截断算子 $\mathcal{C}(\cdot)$ 以抑制适应度波动带来的奖励噪声:

$$r_t = \mathcal{C}_{[r_{\min}, r_{\max}]} \left(\underbrace{w_1 \cdot \tilde{\eta}_t}_{\text{收敛增益}} + \underbrace{w_2 \cdot (d_t - d_{t-1})}_{\text{多样性维持}} + \underbrace{w_3 \cdot \mathbb{I}(f_{\text{best}}^t < f_{\text{global}}^*)}_{\text{全局突破}} \right) \quad (3)$$

其中, $\tilde{\eta}_t$ 为适应度改进率的指数移动平均 (EMA), 用于平滑短期波动; $\mathbb{I}(\cdot)$ 为指示函数, 用于给予打破历史全局最优解的行为稀疏但高额奖励信号。

智能体采用 Q-learning 更新状态-动作价值函数 $Q(s, a)$:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right] \quad (4)$$

决策阶段使用 ϵ -greedy 策略。为增强跳出局部最优的能力, 引入基于计数器的动态逃逸机制: 若 $S_\eta(t) = 0$ 连续 K 代成立, 则提升探索率 $\epsilon \leftarrow \min(\epsilon + \delta, 1.0)$, 并维持该高探索状态直至观测到显著改进。

3.3 增强型多种群协同机制

传统岛屿模型通常采用固定迁移拓扑和静态迁移频率^[6-7]，缺乏对子种群实时演化状态的感知，容易导致无效迁移甚至负迁移。为此，本文提出一种**源-汇驱动的按需协同迁移机制**，在宏观层面根据子种群演化状态动态决定迁移行为，在微观层面通过受控扰动实现知识注入，从而提升多种群协同效率。

3.3.1 演化状态评估与源汇识别

为实现迁移策略的状态感知，算法基于统计指标对各子种群的演化状态进行评估。在第 t 代，对第 i 个子种群 P_i 定义其滑动窗口改进率 $\Delta\mathcal{F}_i(t)$ 及种群多样性 $\mathcal{D}_i(t)$ 为：

$$\begin{aligned}\Delta\mathcal{F}_i(t) &= \frac{f_{\text{best}}(t-L) - f_{\text{best}}(t)}{|f_{\text{best}}(t-L)| + \epsilon}, \\ \mathcal{D}_i(t) &= \frac{1}{N_{\text{sub}}} \sum_{k=1}^{N_{\text{sub}}} \|\mathbf{x}_{i,k} - \bar{\mathbf{x}}_i\|_2.\end{aligned}\quad (5)$$

其中， L 为滑动窗口长度， $\bar{\mathbf{x}}_i$ 表示子种群 P_i 的几何中心。

基于上述指标，算法在每一代将子种群划分为两类功能角色：**源节点 (Source)**：当 $\Delta\mathcal{F}_i > \theta_{\text{high}}$ 时，表明该子种群仍处于活跃搜索阶段，具有可迁移的有效遗传信息；**汇节点 (Sink)**：当 $\Delta\mathcal{F}_i < \theta_{\text{low}}$ 且 $\mathcal{D}_i < \delta_{\text{div}}$ 时，表明子种群已陷入停滞或早熟收敛状态，需要外部干预。

3.3.2 按需触发的救援迁移策略

在完成源汇识别后，仅当系统中同时存在源节点与汇节点时，算法才触发救援迁移操作，从而避免无效迁移带来的资源浪费。算法 2 给出了完整的迁移流程：对于每一个汇节点，从源节点集合中选择多样性较高的子种群作为信息提供方，提取其前 K 个精英个体，并将其注入至汇节点中替换当前最劣个体。

为避免直接复制导致的种群同质化，在迁移过程中对精英个体施加高斯扰动，其生成规则为：

$$\mathbf{x}_{\text{mig}} = \mathbf{x}_{\text{src}} + \mathcal{N}(\mathbf{0}, \sigma_{\text{mig}}^2 \cdot \mathbf{I}), \quad (6)$$

其中 $\sigma_{\text{mig}} = \eta \cdot \|\mathbf{x}_{\text{max}} - \mathbf{x}_{\text{min}}\|$ 为自适应噪声强度。该机制在传递有效遗传模式的同时，引入适量随机扰动，有助于激活停滞种群的局部搜索能力。

Algorithm 2 自适应救援迁移策略

Require: 种群集合 $\mathcal{P} = \{P_1, \dots, P_M\}$ ，动量阈值 $\theta_{\text{high}}, \theta_{\text{low}}$ ，多样性阈值 δ_{div} ，迁移规模 K ，噪声系数 η

Ensure: 更新后的种群集合 $\mathcal{P}$

- 1: 初始化: $\mathcal{S}_{\text{src}} \leftarrow \emptyset, \mathcal{S}_{\text{sink}} \leftarrow \emptyset$
- 2: **Step 1: 演化状态评估与源汇识别**
- 3: **for** $i = 1$ **to** M **do**
- 4: 根据式 (5) 计算进化动量 $\Delta\mathcal{F}_i(t)$ 和多样性 $\mathcal{D}_i(t)$
- 5: **if** $\Delta\mathcal{F}_i > \theta_{\text{high}}$ **then**
- 6: $\mathcal{S}_{\text{src}} \leftarrow \mathcal{S}_{\text{src}} \cup \{P_i\}$ ▷ 标记为源节点
- 7: **end if**
- 8: **if** $\Delta\mathcal{F}_i < \theta_{\text{low}}$ **and** $\mathcal{D}_i < \delta_{\text{div}}$ **then**
- 9: $\mathcal{S}_{\text{sink}} \leftarrow \mathcal{S}_{\text{sink}} \cup \{P_i\}$ ▷ 标记为汇节点
- 10: **end if**
- 11: **end for**
- 12: **Step 2: 按需执行救援迁移**
- 13: **if** $\mathcal{S}_{\text{src}} \neq \emptyset$ **and** $\mathcal{S}_{\text{sink}} \neq \emptyset$ **then**
- 14: **for each** $P_{\text{sink}} \in \mathcal{S}_{\text{sink}}$ **do**
- 15: ▷ 选择多样性最高的源种群
- 16: $P_{\text{src}} \leftarrow \arg \max_{P \in \mathcal{S}_{\text{src}}} \text{Var}(P)$
- 17: ▷ 提取 Top-K 精英并计算自适应噪声强度
- 18: $\mathbf{X}_{\text{elite}} \leftarrow \text{SelectBest}(P_{\text{src}}, K)$
- 19: $\sigma_{\text{mig}} \leftarrow \eta \cdot \|\mathbf{x}_{\text{max}} - \mathbf{x}_{\text{min}}\|$
- 20: **for** $k = 1$ **to** K **do**
- 21: ▷ 注入高斯噪声并替换汇种群最劣个体
- 22: $\mathbf{x}_{\text{mig}} \leftarrow \mathbf{X}_{\text{elite}}[k] + \mathcal{N}(\mathbf{0}, \sigma_{\text{mig}}^2 \cdot \mathbf{I})$
- 23: $P_{\text{sink}} \leftarrow \text{ReplaceWorst}(P_{\text{sink}}, \mathbf{x}_{\text{mig}})$
- 24: **end for**
- 25: **end for**
- 26: **end if**
- 27: **return** $\mathcal{P}$

3.3.3 多智能体协同与策略同步

在 MPRL-GA 的分布式框架下，各子种群的强化学习智能体并行运行并独立更新策略。为促进经验共享并缓解局部策略收敛差异，本文引入一种**基于软更新的策略同步机制**作为工程性增强手段。

每隔同步周期 T_{sync} ，对各智能体的 Q 表进行加权融合：

$$Q_i(s, a) \leftarrow (1 - \tau)Q_i(s, a) + \tau \cdot \frac{1}{M} \sum_{j=1}^M Q_j(s, a), \quad (7)$$

其中 $\tau \in [0, 1]$ 为同步系数，用于平衡个体经验与群体平均策略。该机制能够在不强制一致化的前提下，引导策略信息在子种群间缓慢传播，从而提升整体学习稳定性。

表 3: 基准测试函数详细定义

ID	函数名称	数学表达式	搜索空间
<i>Unimodal Functions (单峰函数)</i>			
F_1	Sphere	$f(\mathbf{x}) = \sum_{i=1}^D x_i^2$	$[-100, 100]^D$
F_2	Schwefel 2.22	$f(\mathbf{x}) = \sum_{i=1}^D x_i + \prod_{i=1}^D x_i $	$[-10, 10]^D$
F_3	Sum Squares	$f(\mathbf{x}) = \sum_{i=1}^D ix_i^2$	$[-10, 10]^D$
<i>Multimodal Functions (多峰函数)</i>			
F_4	Rastrigin	$f(\mathbf{x}) = 10D + \sum_{i=1}^D (x_i^2 - 10 \cos(2\pi x_i))$	$[-5.12, 5.12]^D$
F_5	Rosenbrock	$f(\mathbf{x}) = \sum_{i=1}^{D-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$	$[-30, 30]^D$
F_6	Ackley	$f(\mathbf{x}) = -20 \exp \left(-0.2 \sqrt{\frac{1}{D} \sum_{i=1}^D x_i^2} \right) - \exp \left(\frac{1}{D} \sum_{i=1}^D \cos(2\pi x_i) \right) + 20 + e$	$[-32, 32]^D$
F_7	Griewank	$f(\mathbf{x}) = \frac{1}{4000} \sum_{i=1}^D x_i^2 - \prod_{i=1}^D \cos \left(\frac{x_i}{\sqrt{i}} \right) + 1$	$[-600, 600]^D$
F_8	Levy	$f(\mathbf{x}) = \sin^2(\pi w_1) + \sum_{i=1}^{D-1} (w_i - 1)^2 [1 + 10 \sin^2(\pi w_i + 1)] + (w_D - 1)^2 [1 + \sin^2(2\pi w_D)]$ 其中 $w_i = 1 + \frac{x_i - 1}{4}$	$[-10, 10]^D$
F_9	Schwefel	$f(\mathbf{x}) = 418.9829D - \sum_{i=1}^D x_i \sin(\sqrt{ x_i })$	$[-500, 500]^D$

3.4 算法复杂度与实现开销分析

在计算复杂度方面, MPRL-GA 的主体仍由遗传算法演化过程构成, 其时间复杂度为 $O(N \cdot G)$, 其中 N 为种群规模, G 为迭代代数。强化学习模块采用表格型 Q-learning, 其状态空间规模为 27, 动作空间规模有限, 因此每代更新的额外开销为常数级。

多种群救援迁移机制仅在检测到子种群停滞时触发, 其计算代价主要来源于统计量计算与精英个体替换, 对整体运行时间影响有限。实验结果表明, 在相同种群规模与迭代次数下, 所提出方法的运行时间相较于标准 GA 有一定增加, 但仍处于可接受范围内。

4 仿真实验

本章通过一系列连续优化基准函数, 对本文提出的多种群强化学习控制遗传算法框架进行仿真验证, 并与多种典型算法进行对比。主要考察算法在不同类型函数上的收敛性能、多样性保持能力以及结果的统计显著性, 同时通过策略可视化分析强化学习控制器的行为模式。

4.1 实验设置

4.1.1 实验环境

为了全面评估 MPRL-GA 的优化性能及鲁棒性, 本节详细阐述实验所采用的基准函数集、对比算法配置以及评价指标体系。所有实验均在通用 PC 平台上

进行 (配置为 Intel Core i9 CPU, 32 GB 内存)。为了确保实验的公平性, 所有算法实现均基于统一的实验框架, 共享相同的编码方式、适应度评估过程以及随机数初始化接口。

4.1.2 基准测试函数

实验选取 9 个进化计算领域常用的连续优化基准函数作为测试集, 其定义与常用测试集合一致^[17], 详细定义见表 3。测试函数划分如下:

- **单峰函数 (Unimodal, $F_1 \sim F_3$):** 用于评估算法的局部开发能力与收敛速度。
- **多峰函数 (Multimodal, $F_4 \sim F_9$):** 用于评估算法的全局探索能力及跳出局部最优的能力; 其中部分函数 (如 Rosenbrock) 具有狭窄谷结构与变量耦合特性。

除非另有说明, 所有函数的搜索维度设置为 $D = 30$ 。各函数的理论最优值与搜索区间以表 3 所给定义为准,

4.1.3 评价指标

鉴于元启发式算法的随机特性, 每个算法在每个函数上独立运行 **30 次**。我们采用以下两项指标进行量化评估:

1. **收敛精度 (Mean):** 30 次独立运行获得的全局最优解的算术平均值。该值反映了算法的平均求解质量, 数值越接近 0 表示精度越高。

表 4: 实验参数详细设置表

类别	参数名称 (符号)	数值/策略
1. 通用环境 (General Settings)		
	独立运行次数 (Runs)	30
	问题维度 (D)	30
	种群规模 (N)	200
	最大迭代次数 ($G_{\max}$)	2000 (消融) / 1000 (对比)
2. 基础遗传算法 (Base GA)		
	交叉概率 (P_c)	0.9
	变异概率 (P_m)	0.01
	选择算子	锦标赛选择 (Size=2)
3. RL 控制器 (RL Controller)		
	学习率 (α)	0.1
	折扣因子 (γ)	0.9
	探索策略 (ϵ)	线性衰减 (0.1 $\rightarrow$ 0.01)
	状态空间 ($ S $)	27 (分位数离散 + 三进制编码)
	动作空间 ($ A $)	6 种算子组合
4. 多种群协同 (Multi-Population)		
	子种群数量 (M)	4
	子种群规模 (N_{sub})	50
	迁移周期 (T_{mig})	10 代 (仅作为检测频率, 按需触发救援迁移)
	救援噪声强度 (σ_{mig})	$0.05 \times \text{Range}$

2. **稳定性 (Std)**: 30 次运行结果的标准差。该值反映了算法对初始种群随机分布的鲁棒性, 数值越小表示算法越稳定。

4.1.4 算法配置与公平性约束

为了验证 MPRL-GA 的竞争力, 我们设计了两组实验: (1) **消融实验组**, 对比 Baseline GA、GA-MP (仅多种群)、GA-RL (仅 RL 控制) 与完整模型; (2) **对比实验组**, 对比 6 种经典元启发式算法, 包括 ACO, DE, ES, GA, PSO, SA [2,18-22]。

4.1.5 算法参数配置

根据实验目的, 消融实验采用 **2,000 代**迭代以观察长期收敛行为, 综合对比实验采用 **1,000 代**以遵循通用测试标准。所有实验种群规模固定为 $N = 200$, 其余参数见表 4。

4.2 机制有效性分析: 消融实验

为分析 MPRL-GA 框架中“强化学习算子调度”与“多种群救援机制”的独立贡献及其协同效应, 本节采用消融实验设计, 在统一的进化预算 ($G_{\max} = 2000$) 下, 对完整模型 (MPRL-GA) 及其三个简化变体进行对比分析。实验重点考察不同机制在单峰与多峰适应度景观中的行为差异及其对收敛过程的影响。

4.2.1 收敛动力学与曲线形态分析

图 2 给出了各算法在典型基准函数上的平均收敛轨迹。从收敛速度与平台期行为可以观察到不同机制在进化过程中的作用差异。

单峰函数上的早期收敛特性: 在单峰函数 (如 Sphere 和 Sum Squares) 上, 引入强化学习控制的 GA-RL 在进化早期表现出明显更快的下降趋势。例如, 在 Sphere 函数中, GA-RL 在约 200 代内即可将平均适应度降低至 10^{-2} 量级, 而 Baseline GA 在相同阶段仍停留在 10^{-1} 以上, 反映出自适应算子调度在搜索初期对探索强度的有效调节。

多峰函数中的停滞行为与逃逸能力: 在复杂多峰函数上, 多种群救援机制的作用更加显著。以 Schwefel 函数为例, GA-RL 在进化中后期出现明显平台, 其最终均值仍在 10^{-2} 量级; 相比之下, MPRL-GA 在多次停滞后仍能实现阶段性下降, 最终将平均适应度进一步降低至 10^{-3} 量级。收敛曲线中呈现的阶梯状下降形态, 与“停滞检测—救援迁移触发”的设计机制高度一致, 表明按需引入外部遗传信息有助于恢复搜索活性并跳出局部最优。

4.2.2 统计结果与模块贡献量化

表 5 汇总了各算法在 2000 代进化后的最终统计结果 (Mean $\pm$ Std)。从均值与稳定性两个角度, 可以得到以下结论: 表 5 汇总了各算法在 2000 代进化后的最终统计结果 (Mean $\pm$ Std), 从中可以更定量地分析各模块的贡献。

强化学习算子调度的主要贡献: 首先, 在多峰函数 Rastrigin 上, 引入 RL 模块的 GA-RL 相比 Baseline GA 将平均误差从 7.7×10^{-1} 显著降低至 2.0×10^{-2} , 改进幅度超过 97%, 表明算子自适应调度在复杂搜索空间中能够显著提升平均求解质量。

缺乏状态感知的多种群结构的局限性: 其次, 仅引入多种群结构的 GA-MP 在部分函数上并未带来稳定收益。例如在 Schwefel 函数上, GA-MP 的平均结果反而由 7.31×10^2 上升至 8.74×10^2 , 出现性能退化。这一现象说明, 在缺乏状态感知与选择性迁移策略的情况下, 固定迁移机制可能引入低质量遗传信息, 从而对整体搜索产生负面影响。

双机制协同带来的综合性能提升: 最后, 完整模型 MPRL-GA 在所有测试函数上均获得最优或接近最优的均值表现。特别是在 Rosenbrock 和 Levy 等具有强耦合或复杂地貌的函数上, MPRL-GA 相比单一机制变体进一步降低了最终均值, 并在多数情况下表现出

表 5: 消融实验统计结果对比 (Mean $\pm$ Std). 基于 2000 代进化的最终适应度评估。★ 表示最优结果, 绿色背景突出了完整模型 (MPRL-GA) 相比于单一机制变体的显著优势。

基准函数	GA	GA-MP		GA-RL		MPRL-GA (Full)	
	Baseline	结果	提升率	结果	提升率	结果	提升率
单峰函数 (Unimodal Functions)							
Sphere	3.45 ± 1.14	1.63 ± 0.68	52.7%	$4.00 \times 10^{-2} \pm 2.00 \times 10^{-2}$	98.9%	★ $1.65 \times 10^{-3} \pm 9.16 \times 10^{-4}$	99.95%
Sum Squares	$4.50 \times 10^{-1} \pm 1.70 \times 10^{-1}$	$2.60 \times 10^{-1} \pm 1.00 \times 10^{-1}$	42.6%	$1.00 \times 10^{-2} \pm 5.40 \times 10^{-3}$	97.1%	★ $3.61 \times 10^{-4} \pm 2.09 \times 10^{-4}$	99.92%
多峰函数 (Multimodal Functions)							
Rastrigin	$7.70 \times 10^{-1} \pm 2.30 \times 10^{-1}$	$5.70 \times 10^{-1} \pm 1.80 \times 10^{-1}$	25.2%	$2.00 \times 10^{-2} \pm 9.00 \times 10^{-3}$	97.3%	★ $4.91 \times 10^{-4} \pm 2.15 \times 10^{-4}$	99.94%
Ackley	$6.60 \times 10^{-1} \pm 1.30 \times 10^{-1}$	$4.50 \times 10^{-1} \pm 9.00 \times 10^{-2}$	30.7%	$5.70 \times 10^{-1} \pm 1.40 \times 10^{-1}$	12.4%	★ $3.67 \times 10^{-3} \pm 1.12 \times 10^{-3}$	99.44%
Griewank	$1.03 \pm 1.00 \times 10^{-2}$	$9.40 \times 10^{-1} \pm 8.00 \times 10^{-2}$	9.0%	$6.40 \times 10^{-1} \pm 1.70 \times 10^{-1}$	38.0%	★ $2.00 \times 10^{-2} \pm 2.00 \times 10^{-2}$	97.93%
Rosenbrock	$2.52 \times 10^2 \pm 6.36 \times 10^1$	$1.54 \times 10^2 \pm 4.36 \times 10^1$	38.7%	$7.51 \times 10^1 \pm 3.88 \times 10^1$	70.2%	★ $6.47 \times 10^1 \pm 3.10 \times 10^1$	74.30%
Levy	$2.00 \times 10^{-2} \pm 4.82 \times 10^{-3}$	$8.86 \times 10^{-3} \pm 2.34 \times 10^{-3}$	44.0%	$1.00 \times 10^{-2} \pm 3.75 \times 10^{-3}$	33.5%	★ $2.02 \times 10^{-5} \pm 1.30 \times 10^{-5}$	99.87%
Schwefel	$7.31 \times 10^2 \pm 2.11 \times 10^2$	$8.74 \times 10^2 \pm 2.88 \times 10^2$	-19.4%	$7.00 \times 10^{-2} \pm 3.00 \times 10^{-2}$	> 99.99%	★ $2.40 \times 10^{-3} \pm 9.35 \times 10^{-4}$	> 99.99%
Styblinski-Tang*	$-1.16 \times 10^3 \pm 1.56 \times 10^1$	$-1.09 \times 10^3 \pm 2.20 \times 10^1$	-5.3%	$-1.17 \times 10^3 \pm 1.00 \times 10^{-2}$	1.6%	★ $-1.17 \times 10^3 \pm 8.35 \times 10^{-4}$	1.64%

*Styblinski-Tang 为最大化问题 (数值越大越好), 其余均为最小化问题 (数值越小越好)

提升率 = (Baseline - 结果) / Baseline $\times$ 100%, 表示相对于基线 GA 的性能改进

颜色编码: 红色 $\geq 70\%$, 橙色 30%-70%, 青色 $< 30\%$, 蓝色表示性能退化




图 2: MPRL-GA 及其消融变体在 2000 代进化过程中的收敛曲线对比。可以观察到, 完整模型 (MPRL-GA) 在多数基准函数上保持了更稳定的收敛趋势, 体现了 RL 控制与多种群机制在进化过程中的协同作用。

更小的标准差。这表明, 强化学习提供的微观算子自适应能力与多种群救援机制提供的宏观多样性维持能力

表 6: MPRL-GA 与 6 种传统优化算法在 9 个基准函数上的实验结果对比 (Mean $\pm$ Std)。★ 表示最优结果, 下划线表示次优结果, 绿色背景标注提出方法。

基准函数	ACO	DE	ES	GA	PSO	SA	MPRL-GA
单峰函数 (Unimodal Functions)							
Sphere	$2.24 \times 10^1 \pm 5.56 \times 10^0$	$3.04 \times 10^4 \pm 5.16 \times 10^3$	$8.58 \times 10^1 \pm 1.24 \times 10^2$	$7.01 \times 10^1 \pm 1.66 \times 10^1$	★ $1.49 \times 10^{-4} \pm 1.31 \times 10^{-4}$	$3.93 \times 10^4 \pm 4.60 \times 10^3$	$1.13 \times 10^{-1} \pm 4.84 \times 10^{-2}$
Sum Squares	<u>$2.38 \times 10^0 \pm 7.32 \times 10^{-1}$</u>	$4.51 \times 10^3 \pm 6.15 \times 10^2$	$1.77 \times 10^1 \pm 3.94 \times 10^1$	$1.27 \times 10^1 \pm 2.78 \times 10^0$	$1.33 \times 10^1 \pm 4.27 \times 10^1$	$7.70 \times 10^3 \pm 8.08 \times 10^2$	★ $3.15 \times 10^{-2} \pm 1.58 \times 10^{-2}$
多峰函数 (Multimodal Functions)							
Rastrigin	$3.38 \times 10^2 \pm 1.35 \times 10^1$	$4.55 \times 10^2 \pm 2.22 \times 10^1$	$2.00 \times 10^2 \pm 2.63 \times 10^1$	<u>$1.85 \times 10^1 \pm 3.02 \times 10^0$</u>	$5.45 \times 10^1 \pm 2.02 \times 10^1$	$5.15 \times 10^2 \pm 2.10 \times 10^1$	★ $5.14 \times 10^{-2} \pm 1.49 \times 10^{-2}$
Ackley	$2.61 \times 10^0 \pm 2.80 \times 10^{-1}$	$1.99 \times 10^1 \pm 7.40 \times 10^{-3}$	$1.90 \times 10^1 \pm 3.14 \times 10^0$	$3.07 \times 10^0 \pm 2.77 \times 10^{-1}$	★ $3.32 \times 10^{-3} \pm 3.77 \times 10^{-3}$	$2.04 \times 10^1 \pm 1.40 \times 10^{-1}$	<u>$7.12 \times 10^{-2} \pm 1.51 \times 10^{-2}$</u>
Griewank	$1.20 \times 10^0 \pm 4.66 \times 10^{-2}$	$2.74 \times 10^2 \pm 4.65 \times 10^1$	$2.14 \times 10^0 \pm 2.47 \times 10^0$	$1.63 \times 10^0 \pm 1.50 \times 10^{-1}$	★ $9.33 \times 10^{-3} \pm 1.25 \times 10^{-2}$	$6.95 \times 10^2 \pm 5.31 \times 10^1$	<u>$3.34 \times 10^{-1} \pm 7.52 \times 10^{-2}$</u>
Rosenbrock	$2.13 \times 10^4 \pm 1.08 \times 10^4$	$6.20 \times 10^7 \pm 2.07 \times 10^7$	<u>$1.53 \times 10^3 \pm 2.30 \times 10^3$</u>	$2.71 \times 10^3 \pm 1.14 \times 10^3$	$6.21 \times 10^3 \pm 2.24 \times 10^4$	$7.02 \times 10^7 \pm 1.44 \times 10^7$	★ $1.21 \times 10^2 \pm 4.52 \times 10^1$
Levy	$3.13 \times 10^0 \pm 9.34 \times 10^{-1}$	$1.28 \times 10^2 \pm 1.93 \times 10^1$	$4.38 \times 10^1 \pm 8.57 \times 10^0$	$3.37 \times 10^{-1} \pm 5.98 \times 10^{-2}$	★ $5.79 \times 10^{-6} \pm 8.50 \times 10^{-6}$	$2.33 \times 10^2 \pm 1.86 \times 10^1$	<u>$2.01 \times 10^{-3} \pm 6.77 \times 10^{-4}$</u>
Schwefel	$1.13 \times 10^4 \pm 2.40 \times 10^2$	$9.72 \times 10^3 \pm 3.59 \times 10^2$	$6.57 \times 10^3 \pm 6.08 \times 10^2$	<u>$1.55 \times 10^3 \pm 3.73 \times 10^2$</u>	$4.02 \times 10^3 \pm 5.33 \times 10^2$	$9.11 \times 10^3 \pm 4.59 \times 10^2$	★ $1.83 \times 10^{-1} \pm 7.78 \times 10^{-2}$
Styblinski-Tang*	$-9.62 \times 10^2 \pm 5.58 \times 10^1$	$-8.14 \times 10^2 \pm 5.70 \times 10^1$	$-1.34 \times 10^3 \pm 5.16 \times 10^1$	<u>$-1.51 \times 10^3 \pm 2.53 \times 10^1$</u>	$-1.36 \times 10^3 \pm 3.03 \times 10^1$	$-7.63 \times 10^2 \pm 4.34 \times 10^1$	★ $-1.57 \times 10^3 \pm 3.15 \times 10^{-2}$

*Styblinski-Tang 为最大化问题 (数值越大越好), 其余均为最小化问题 (数值越小越好)

对比算法: ACO (蚁群), DE (差分进化), ES (进化策略), GA (遗传算法), PSO (粒子群), SA (模拟退火)




图 3: MPRL-GA 与 6 种对比算法在 9 个基准函数上的收敛曲线对比。该图展示了不同算法在进化过程中的平均适应度变化情况, 其中完整模型 (MPRL-GA) 在部分复杂函数上表现出不同于快速收敛型算法的收敛特征。

4.3 综合性能评估: 与经典算法对比

为评估 MPRL-GA 在通用连续优化问题上的整体适用性, 本节将其与六种经典元启发式算法 (ACO, DE, ES, GA, PSO, SA) 在统一的迭代预算 ($G_{\max} = 1000$) 下进行横向对比。比较重点放在不同适应度景观中算

法的收敛行为、最终求解精度以及结果稳定性。

4.3.1 收敛特性分析

图 3 展示了各算法在典型基准函数上的平均收敛轨迹, 可以观察到不同算法在搜索阶段上的明显侧重

差异。

单峰函数上的早期收敛速度对比：在单峰函数（如 F_1 Sphere）上，PSO 在进化早期表现出最快的下降速度，其适应度在前 100 代内即可降低至 10^{-4} 量级，明显快于其他算法。这一现象与粒子群算法利用全局最优引导个体快速逼近最优解的机制相一致。相比之下，MPRL-GA 在早期的收敛速度相对平缓，但其曲线在整个迭代过程中保持稳定下降，表明该方法在简单地貌中更倾向于维持搜索多样性而非激进收敛。

多峰函数中的持续搜索能力：在多峰函数上，算法间差异更加显著。以 F_4 Rastrigin 为例，PSO 与 DE 的收敛曲线在约 200 代后趋于平台，其最终适应度仍停留在 10^1 量级；相比之下，MPRL-GA 的收敛过程未出现明显停滞，并在后期持续下降至 10^{-2} 量级。在具有强耦合结构的 F_5 Rosenbrock 函数上，DE 与 ACO 的曲线呈现出明显的阶梯式下降，而 MPRL-GA 的收敛轨迹更为平滑，显示出其在复杂地貌中持续探索的能力。这表明，多种群机制与强化学习策略的结合，有助于算法在复杂搜索空间中缓解早熟停滞问题。

4.3.2 统计结果分析

表 6 给出了各算法在 9 个基准函数上独立运行 30 次后的统计结果（Mean $\pm$ Std），从定量角度反映了不同方法的求解精度与稳定性。

复杂多峰函数上的求解精度优势：从求解精度来看，MPRL-GA 在 9 个测试函数中有 5 个取得了最优均值结果，且在其余函数上也保持了具有竞争力的表现。尤其在复杂多峰函数 F_9 Schwefel 上，传统算法的最终均值集中在 10^3 至 10^4 数量级（例如 GA 为 1.55×10^3 ，ACO 为 1.13×10^4 ），而 MPRL-GA 将平均适应度进一步降低至 1.83×10^{-1} 。这一数量级差异表明，在存在大量深层局部最优的情形下，按需救援迁移机制能够显著提升搜索的有效性。

简单地貌下快速收敛算法的相对优势：在部分结构相对简单的函数上，MPRL-GA 并非始终占优。例如在 F_1 Sphere 和 F_6 Ackley 上，PSO 分别取得了 1.49×10^{-4} 和 3.32×10^{-3} 的最优均值，而 MPRL-GA 的结果为 1.13×10^{-1} 和 7.12×10^{-2} 。这与前述收敛曲线分析一致，说明在平滑、低欺骗性的适应度景观中，快速收敛型算法具有天然优势。

多次独立运行下的结果稳定性比较：从稳定性角度看，MPRL-GA 在多种复杂函数上表现出较小的标准差。例如在 Styblinski-Tang 函数（最大化问题）上，MPRL-GA 的标准差仅为 3.15×10^{-2} ，明显低于 GA 的 2.53×10^1 和 ES 的 5.16×10^1 。这表明在多次独立

运行中，MPRL-GA 的搜索行为更加稳定，对初始种群分布的敏感性较低。

5 结论

本文针对高维复杂优化问题中遗传算法算子配置依赖经验、易发生早熟收敛等问题，提出了一种融合强化学习控制与多种群协同机制的 MPRL-GA 框架。该方法通过基于分位数统计的 Q-Learning 控制器实现了演化算子的尺度不变自适应调度，并结合源-汇驱动的救援迁移机制，在维持种群多样性的同时有效缓解了局部最优停滞与负迁移风险。实验结果表明，MPRL-GA 在 9 个基准函数上整体表现出较好的收敛精度与稳定性，尤其在 Schwefel 等复杂多峰函数中展现出更强的全局搜索能力。未来将进一步探索深度强化学习在更高维状态空间中的应用，并将该框架拓展至受约束与工程优化问题中。

参考文献

- [1] HOLLAND J H. Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artificial intelligence[M]. Ann Arbor, MI: University of Michigan Press, 1975.
- [2] GOLDBERG D E. Genetic algorithms in search, optimization, and machine learning[M]. Reading, MA: Addison-Wesley, 1989.
- [3] WOLPERT D H, MACREADY W G. No free lunch theorems for optimization[J/OL]. IEEE Transactions on Evolutionary Computation, 1997, 1(1): 67-82. DOI: [10.1109/4235.585893](https://doi.org/10.1109/4235.585893).
- [4] RECHENBERG I. Evolutionsstrategie: Optimierung technischer systeme nach prinzipien der biologischen evolution[M]. Stuttgart: Frommann-Holzboog, 1973.
- [5] EIBEN A E, HINTERDING R, MICHALEWICZ Z. Parameter control in evolutionary algorithms [J/OL]. IEEE Transactions on Evolutionary Computation, 1999, 3(2): 124-141. DOI: [10.1109/4235.771166](https://doi.org/10.1109/4235.771166).
- [6] ALBA E. Parallel metaheuristics: A new class of algorithms[M]. Wiley-Interscience, 2005.

- [7] CANTÚ-PAZ E. Efficient and accurate parallel genetic algorithms[M/OL]. Kluwer Academic Publishers / Springer, 2000. DOI: [10.1007/978-1-4615-4369-5](https://doi.org/10.1007/978-1-4615-4369-5).
- [8] SUTTON R S, BARTO A G. Reinforcement learning: An introduction[M]. 2nd ed. Cambridge, MA: MIT Press, 2018.
- [9] WATKINS C J C H, DAYAN P. Q-learning[J/OL]. Machine Learning, 1992, 8(3-4): 279-292. DOI: [10.1007/BF00992698](https://doi.org/10.1007/BF00992698).
- [10] ÁLVARO FIALHO, COSTA L D, SCHOE-NAUER M, et al. Extreme value based adaptive operator selection[C/OL]//Lecture Notes in Computer Science: Vol. 5199 Parallel Problem Solving from Nature – PPSN X. Springer, 2008: 175-184. DOI: [10.1007/978-3-540-87700-4_18](https://doi.org/10.1007/978-3-540-87700-4_18).
- [11] MATURANA J, LARDEUX F, SAUBION F. Autonomous operator management for evolutionary algorithms[J/OL]. Journal of Heuristics, 2010, 16: 881-909. DOI: [10.1007/s10732-010-9125-3](https://doi.org/10.1007/s10732-010-9125-3).
- [12] 周明, 孙树栋. 遗传算法原理及应用[M]. 北京: 国防工业出版社, 1999.
- [13] SRINIVAS M, PATNAIK L M. Adaptive probabilities of crossover and mutation in genetic algorithms[J/OL]. IEEE Transactions on Systems, Man, and Cybernetics, 1994, 24(4): 656-667. DOI: [10.1109/21.286385](https://doi.org/10.1109/21.286385).
- [14] 夏小云, 周育人. 蚁群优化算法的理论研究进展[J/OL]. 智能系统学报, 2016, 11(1): 27-36. DOI: [10.11992/tis.201510002](https://doi.org/10.11992/tis.201510002).
- [15] 高阳, 陈世福, 陆鑫. 强化学习研究综述[J]. 自动化学报, 2004, 30(1): 86-100.
- [16] 刘泽, 穆超, 孙长银. 深度强化学习算法与应用研究现状综述[J/OL]. 智能科学与技术学报, 2020, 2(4): 314-326. DOI: [10.11959/j.issn.2096-6652.202034](https://doi.org/10.11959/j.issn.2096-6652.202034).
- [17] JAMIL M, YANG X S. A literature survey of benchmark functions for global optimisation problems[J/OL]. International Journal of Mathematical Modelling and Numerical Optimisation, 2013, 4(2): 150-194. DOI: [10.1504/IJMMNO.2013.055204](https://doi.org/10.1504/IJMMNO.2013.055204).
- [18] DORIGO M, MANIEZZO V, COLORNI A. Ant system: optimization by a colony of cooperating agents[J/OL]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 1996, 26(1): 29-41. DOI: [10.1109/3477.484436](https://doi.org/10.1109/3477.484436).
- [19] STORN R, PRICE K. Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces[J/OL]. Journal of Global Optimization, 1997, 11(4): 341-359. DOI: [10.1023/A:1008202821328](https://doi.org/10.1023/A:1008202821328).
- [20] BEYER H G, SCHWEFEL H P. Evolution strategies – a comprehensive introduction[J/OL]. Natural Computing, 2002, 1: 3-52. DOI: [10.1023/A:1015059928466](https://doi.org/10.1023/A:1015059928466).
- [21] KENNEDY J, EBERHART R. Particle swarm optimization[C/OL]//Proceedings of ICNN'95 – International Conference on Neural Networks. 1995: 1942-1948. DOI: [10.1109/ICNN.1995.488968](https://doi.org/10.1109/ICNN.1995.488968).
- [22] KIRKPATRICK S, JR. C D G, VECCHI M P. Optimization by simulated annealing[J/OL]. Science, 1983, 220(4598): 671-680. DOI: [10.1126/science.220.4598.671](https://doi.org/10.1126/science.220.4598.671).